

Классификация суперпозиций движений физической активности*

Проскурин А. Д., Бельх Е. А.

proskurin.ad@phystech.edu, belyh.ea@phystech.edu

Московский физико-технический институт (государственный университет), Москва

В данной работе рассматривается задача анализа поведения человека по измерениям датчиков мобильного телефона: исследуются временные ряды, построенные по показаниям акселерометра телефона. Данные представляют собой временные ряды сигнала, не имеющего точной периодики, а также содержащий неизвестную суперпозицию физических моделей. В работе ищется оптимальный способ сегментации и оптимальное описание временного ряда. Строится метрическое пространство описаний элементарных действий. Предложен новый способ классификации и анализа сложных движений.

Ключевые слова: *машинное обучение, временные ряды, классификация, распознавание физической деятельности, суперпозиция движений.*

Classification of superposition of physical activity*

Proskurin A. D., Belykh E. A

Moscow Institute of Physics and Technology (state university), Moscow

Here should be abstract in English.

Keywords: *machine learning, time series, classification, physical activity recognition, action superposition.*

Введение

Современные мобильные телефоны содержат в себе множество разнообразных датчиков, таких как микрофон, камера, акселерометр и другие. Данные с этих датчиков позволяют провести анализ действий человека, что в перспективе поможет следить за его физическим и душевным состоянием. Целью данной работы является распознать сложные движения человека, являющиеся суперпозицией более простых движений, используя данные акселерометра телефона. Эти данные являются непериодическими временными рядами, поэтому одной из задач является поиск оптимального способа сегментации и описания временного ряда, а также построение метрического пространства описаний физических движений.

Задача анализа действий человека по временным рядам, полученным с помощью акселерометра, рассматривалась в большом количестве работ. В то же время, многие работы рассматривают движение как однородный процесс, а не суперпозицию нескольких действий. Для классификации временных рядов акселерометра используются различные методы. Так, в [4] исследуются методы построения нейронной сети оптимальной структуры. Найденная устойчивая модель описывается с помощью генетического алгоритма на уровне нейронов путем оптимизации структурных параметров. В [6] помимо нейронных

Научный руководитель: Стрижов В. В. Задачу поставил: Стрижов В. В. Консультанты: Владимирова М. Р., Малькова А. С.

сетей используется алгоритм k ближайших соседей, для которого ищутся оптимальные параметры. Наиболее оптимальным оказывается комбинирование продвинутых алгоритмов сегментации и алгоритма k ближайших соседей. В [1] и [2] исследуются различные методы признакового описания временных рядов, на основе которых проводится классификация. При этом, в [1] в качестве признаковых описаний используются параметры аппроксимирующих моделей, а в [2] используется модель авторегрессии и модель сингулярного спектра временного ряда. В нашей работе предлагается также рассмотреть инвариантные преобразования временных рядов, как это было сделано в [7]. В некоторых работах рассматривается композиция движений, либо зависимость движения от местоположения акселерометра. Так, в [18] используются три классификатора: наивный байесовский, метод k ближайших соседей, решающее дерево. С их помощью производится анализ тринадцати типов движений, некоторые из которых являются простыми, а некоторые композицией простых. Особый интерес представляют работы [22], [19] и [21], в которых описываются алгоритмы анализа не только типа физической активности человека, но и анализа местоположения акселерометра во время физической активности. При этом, во всех трех работах используются разные способы описания временных рядов и их классификации. Так, в [21] используется динамическая байесовская сеть. В [22] используется алгоритм динамической трансформации временной шкалы для нахождения оптимального соответствия между временными рядами, а затем преобразованные ряды классифицируются с помощью алгоритма k ближайших соседей. В [19] используются более продвинутые алгоритмы: сначала применяется гистограмма направленных градиентов для преобразования временных рядов и приведения их к более простому виду. Затем классификация рядов по типам физической активности и местоположению акселерометра делается с помощью алгоритма AdaBoost.

В качестве базовых алгоритмов рассматриваются методы классификации временных рядов, описанные в более ранних работах. Так, в работе [1] был рассмотрен метод классификации, основанный на признаковом описании ряда. Для каждого ряда строится его информативное признаковое описание, позволяющее получить точные классификаторы с хорошей обобщающей способностью. При этом возникают задачи выбора конкретных используемых признаков и выбора аппроксимирующей модели для построения признакового пространства. В работе были исследованы методы, использующие в качестве признаковых описаний параметры рядов аппроксимирующей модели, было проведено сравнение моделей аппроксимации, а также предложен алгоритм классификации временных рядов в пространстве параметров распределений признаков их сегментов.

В [2] рассматривается задача построения признакового пространства, необходимого для описания рядов и их классификации. Рассматриваются два основных метода построения признакового пространства. Первый метод заключается в экспертном назначении базовых функций и служит для получения базового признакового пространства и классификации. Второй метод заключается в назначении параметрической гипотезы порождения объекта более сложной структуры. Для каждого временного ряда вычисляются оптимальные параметры порождения, то есть в данном случае коэффициенты авторегрессии. Эти вычисленные параметры и составляют новое признаковое пространство.

В нашей работе на основе методов классификации временных рядов, описанных в [1] и [2], построить новый метод классификации. Как и в [1] целью является найти оптимальный способ сегментации ряда. Предполагается, что временные ряды описывают суперпозицию физических действий, а не отдельное действие. Рассматривается взвешенная сумма раз-

личных моделей и инвариантные преобразования рядов: сдвиг и растяжение. В качестве исходных данных используются не только готовые данные WISDM, но и собранные самостоятельно. *<Тут нужно более подробное описание>*

Работа построена следующим образом. *<Описание структуры>*

Постановка задачи

Поставим формально задачу классификации временных рядов. Пусть $D(X, Y)$ — это обучающая выборка, где (X, ρ) образует метрическое пространство временных рядов, Y — это метки временных рядов.

Пусть F — это функция построения множества признаков временного ряда:

$$F : X \rightarrow \mathbb{R}^n$$

Пусть G — многоклассовый классификатор, который переводит признаки в метки:

$$G : \mathbb{R}^n \rightarrow Y$$

Итоговый алгоритм — это композиция некоторого G и F :

$$a = G \circ F$$

Пусть задана некоторая функция потерь $L : X \times Y \times Y \rightarrow \mathbb{R}$, тогда функционал качества имеет вид:

$$Q(a, D) = \frac{1}{|D|} \sum_{(x,y) \in D} L(x, a(x), y).$$

Предлагается в качестве функции потерь использовать идентификатор

$$Q(a, D) = \frac{1}{|D|} \sum_{(x,y) \in D} I(a(x) = y)$$

В методе обучения будем сначала фиксировать F , а после оптимизировать функцию G , тогда наш оптимальный алгоритм принимает следующий вид $a_F = \hat{G} \circ F$, где

$$\hat{G} = \operatorname{argmin}_G (Q(G \circ F, D))$$

Чтобы оценить эффективность метода обучения, мы будем разбивать нашу выборку r раз на тестовую и тренировочную ($D = A_1 \cup B_1 = A_2 \cup B_2 = \dots = A_r \cup B_r$), в таком случае наш критерий качества a_F будет

$$QV(a_F, D) = \frac{1}{r} \sum_{i=1}^r Q(a_F(A_i), B_i)$$

Итоговая цель найти

$$\hat{a} = \operatorname{argmin}_F (QV(a_F, D))$$

Построение признаков

Рассмотрим параметрическую модель, которая будет приближать реальные значения нашего временного ряда:

$$g(w, X) \rightarrow X, \text{ где } w \in \mathbb{R}^n.$$

В качестве параметрической модели рассмотрим авторегрессионную модель $AR(p)$:

Пусть $x = [x_1, x_2, \dots, x_t]$ — временной ряд, где $x_i \in \mathbb{R}$

Тогда $g(w, x) = [\hat{x}_1, \hat{x}_2, \dots, \hat{x}_t]$,

$$\text{где } \hat{x}_k = \begin{cases} x_k, & k = 1, \dots, p, \\ w_0 + \sum_{i=1}^p w_i \cdot x_{k-i}, & k = p+1, \dots, t. \end{cases}$$

Если в качестве ρ взять евклидово расстояние, то оптимальное w определяется следующей формулой:

$$w_g(x) = \arg \min_{w \in \mathbb{R}^n} \sum_{i=1}^t \|x_i - \hat{x}_i\|_2^2$$

Алгоритм классификации

Для завершения построения классификатора временных рядов, необходимо построить классификатор G по обучающей выборке $\{(F(x), y) \mid (x, y) \in D\}$.

Будем для этого использовать модель логистической регрессии:

$$f(x, A, b) = A \cdot F(x) + b, \text{ где } A \in M_{m \times n}, b \in M_{m \times 1} \text{ подбираемые параметры.}$$

Далее из вектора $f(x, A, b)$ получаем вектор вероятностей:

$$pr(x, A, b)_k = \frac{e^{f(x, A, b)_k}}{\sum_{i=1}^n e^{f(x, A, b)_i}}$$

Тогда классификатор примет вид:

$$G(x, y) = \arg \max_{k=1}^m pr_k(x, A, b)$$

В качестве функции оценки качества параметров тогда будет функция:

$$Loss(x, w, A, b) = \sum_{i=1}^m y_i \cdot \log(pr_i(x, A, b))$$

Оптимальные параметры модели определяются следующим образом:

$$\hat{A}, \hat{b} = \arg \min_{A, b} loss(x, w, A, b)$$

Вычислительный эксперимент

Вычислительный эксперимент проводился на данных для задачи классификации типов физической активности человека.

Датасет WISDM

Датасет WISDM [11] содержит показания акселерометра для шести видов человеческой активности:

1. Jogging
2. Walking
3. Upstairs
4. Downstairs
5. Sitting
6. Standing

Необработанные данные, представляющие из себя последовательность размеченных показаний акселерометра (по тройке чисел на каждый отсчет времени с интервалом в 50 миллисекунд), были разбиты на временные ряды длиной по 200 отсчетов (10 секунд).

Модель авторегрессии

Признаковое описание. Каждый временной ряд описывается следующими признаками: среднее значение по каждой из координат, среднее квадратичное отклонение по каждой из координат, средний квадрат ускорения, 10 коэффициентов модели авторегрессии $AR(9)$.

Результаты.

	Walking	Jogging	Upstairs	Downstairs	Sitting	Standing	Total quality
KNN (k = 1)	98.82%	99.40%	93.81%	87.34%	98.04%	100.00%	97.61%
Random forest (100 trees)	99.29%	99.70%	88.50%	81.01%	96.08%	100.00%	96.75%
Log regression	96.00%	99.40%	78.76%	43.04%	92.16%	97.67%	91.10%

Таблица 1. Качество модели авторегрессии на датасете WISDM

Как видно, все три классификатора показывают хорошие результаты и классифицируют данные с точностью более 91%. В то же время, наилучшие результаты показывает KNN, при этом все классификаторы показывают наихудшие результаты для классов «Upstairs» и «Downstairs». При этом, все алгоритмы можно улучшать с помощью, например, добавления дополнительных признаков или перебора параметров классификаторов.

Литература

- [1] Карасиков М.Е., Стрижов В.В. Классификация временных рядов в пространстве параметров порождающих моделей // *Информатика и ее применения*, 2016.
- [2] Кузнецов М.П., Ивкин Н.П. Алгоритм классификации временных рядов акселерометра по комбинированному признаковому описанию // *Машинное обучение и анализ данных*, 2015. Т. 1, № 11. С. 1471 - 1483.
- [3] Исаченко Р.В., Стрижов В.В. Метрическое обучение в задачах многоклассовой классификации временных рядов // *Информатика и ее применения*, 2016, 10(2) : 48-57.
- [4] Задаянчук А.И., Попова М.С., Стрижов В.В. Выбор оптимальной модели классификации физической активности по измерениям акселерометра // *Информационные технологии*. 2016.
- [5] Motrenko A.P., Strijov V.V. Extracting fundamental periods to segment human motion time series // *Journal of Biomedical and Health Informatics*, 2016, Vol. 20, No. 6, 1466 - 1476.
- [6] Ignatov A., Strijov V. Human activity recognition using quasiperiodic time series collected from a single triaxial accelerometer // *Multimedia Tools and Applications*, 2015, 17.05.2015 : 1-14.
- [7] Кузнецова М.В. Классификация временных рядов с использованием инвариантных преобразований // *Выпускная квалификационная работа магистра*, 2015, Московский физико-технический институт.

- [8] *Фадеев И.В.* Выбор иерархических моделей в авторегрессионном прогнозировании // *Магистерская диссертация*, 2013, Московский физико-технический институт.
- [9] *Исаченко Р.В.* Реализация алгоритма классификации временных рядов // *sourceforge.net*, <http://sourceforge.net/p/mlalgorithms/code/HEAD/tree/Group274/Isachenko2015TimeSeries/code/>.
- [10] *Кононенко Д.С.* Оценка параметров инвариантных преобразований в задачах прогнозирования временных рядов // *Магистерская диссертация*, 2013, Московский физико-технический институт.
- [11] *Wisdm's activity prediction dataset* // , 2012, <http://www.cis.fordham.edu/wisdm/dataset.php>.
- [12] *Oliver Amft* Analysis of Movement, Orientation and Rotation-Based Sensing for Phone Placement Recognition // *Sensors*, 2015.
- [13] *Akram Bayat, Marc Pomplun, Duc A. Tran* A Study on Human Activity Recognition Using Accelerometer Data from Smartphones // *The 11th International Conference on Mobile Systems and Pervasive Computing*, 2014.
- [14] *Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, and Jorge L. Reyes-Ortiz* Human Activity Recognition on Smartphones using a Multiclass Hardware-Friendly Support Vector Machine // *Proceedings of the 4th international conference on Ambient Assisted Living and Home Care*, 2012.
- [15] *Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, and Jorge L. Reyes-Ortiz* A Public Domain Dataset for Human Activity Recognition Using Smartphones // *21th European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning*, 2013.
- [16] *Xiangbin Zhu, Huiling Qiu* High Accuracy Human Activity Recognition Based on Sparse Locality Preserving Projections // *PLoS ONE*, 2016.
- [17] *Haritha Vellampalli* Physical Human Activity Recognition Using Machine Learning Algorithms // *Dissertation*, Dublin Institute of Technology, 2017.
- [18] *Muhammad Shoaib, Stephan Bosch, Ozlem Durmaz Incel, Hans Scholten, and Paul J. M. Havinga* Complex Human Activity Recognition Using Smartphone and Wrist-Worn Motion Sensors // *Sensors*, 2016.
- [19] *Shinki Miyamoto, Hitoshi Ogawa* Human Activity Recognition System Including Smartphone Position // *International workshop on Innovations in Information and Communication Science and Technology*, 2014.
- [20] *Charissa Ann Ronao, Sung-Bae Cho* Recognizing human activities from smartphone sensors using hierarchical continuous hidden Markov models // *International Journal of Distributed Sensor Networks*, 2017, Vol. 13(1).
- [21] *Dina Bousdar Ahmed, Korbinian Frank, Oliver Heirich* Recognition of Professional Activities With Displaceable Sensors // *Vehicular Technology Conference*, 2015.
- [22] *Shah Md. Shihab Hasan, Mohshi Masnad, Md. Mohiuddin Khan, Hasan Mahmud, Md. Kamrul Hasan* Human Activity Recognition using Smartphone Sensors with Context Filtering // *The Ninth International Conference on Advances in Computer-Human Interactions*, 2016.