

Классификация суперпозиций движений физической активности*

Проскурин А. Д., Бельх Е. А.

proskurin.ad@phystech.edu, belyh.ea@phystech.edu

Московский физико-технический институт (государственный университет), Москва

В работе рассматривается задача анализа поведения человека по измерениям датчиков мобильного телефона. Исследуются временные ряды, построенные по показаниям акселерометра телефона. Данные представляют собой временные ряды сигнала, не имеющего точной периодики, а также содержащие неизвестную суперпозицию физической активности. В работе ищется оптимальный способ сегментации и оптимальное описание временного ряда. Строится метрическое пространство описаний элементарных действий. Предложен новый способ классификации и анализа сложных движений.

Ключевые слова: *временные ряды, классификация, распознавание физической деятельности, суперпозиция движений.*

Classification of superposition of physical activity*

Proskurin A. D., Belykh E. A

Moscow Institute of Physics and Technology (state university), Moscow

Here should be abstract in English.

Keywords: *machine learning, time series, classification, physical activity recognition, action superposition.*

Введение

Решается задача классификации активности человека, что в перспективе поможет следить за его физическим и душевным состоянием. Целью данной работы является распознать сложные движения человека, являющиеся суперпозицией простых движений, используя данные акселерометра телефона. Задача анализа физической активности человека по временным рядам, полученным с помощью акселерометра, рассматривалась в [...]. При этом, в [...] движение рассматривается как простой процесс, а не суперпозиция нескольких действий.

Для классификации временных рядов акселерометра в [4] используется нейронная сеть оптимальной структуры. Найденная устойчивая модель описывается с помощью генетического алгоритма на уровне нейронов путем оптимизации структурных параметров. В [6] используется алгоритм k ближайших соседей. Результаты показывают, что оптимальным оказывается комбинирование продвинутых алгоритмов сегментации и алгоритма k ближайших соседей. В некоторых работах рассматривается композиция движений, либо зависимость движения от местоположения акселерометра. Так, в [18] используются три классификатора: наивный байесовский, метод k ближайших соседей, решающее дерево. С их помощью производится анализ тринадцати типов движений, некоторые из которых

Научный руководитель: Стрижов В. В. Задачу поставил: Стрижов В. В. Консультанты: Владимирова М. Р., Малькова А. С.

являются простыми, а некоторые композицией простых. Особый интерес представляют работы [22], [19] и [21], в которых описываются алгоритмы анализа не только типа физической активности человека, но и анализа местоположения акселерометра во время физической активности. В [19] применяется гистограмма направленных градиентов для преобразования временных рядов и приведения их к более простому виду. Классификация рядов по типам физической активности и местоположению акселерометра делается с помощью алгоритма AdaBoost.

Одной из задач является поиск оптимального способа сегментации и описания временного ряда, а также построение метрического пространства описаний физической активности. В [1] и [2] исследуются различные методы признакового описания временных рядов, на основе которых проводится классификация. При этом, в [1] в качестве признаковых описаний используются параметры аппроксимирующих моделей, а в [2] используется модель авторегрессии и модель сингулярного спектра временного ряда. В нашей работе предлагается рассмотреть инвариантные преобразования временных рядов, как это было сделано в [7]. В [22], [19] и [21] используются разные способы описания временных рядов и их классификации. Так, в [21] используется динамическая байесовская сеть. В [22] используется алгоритм динамической трансформации временной шкалы для нахождения оптимального соответствия между временными рядами, а затем преобразованные ряды классифицируются с помощью алгоритма k ближайших соседей.

В [2] рассматривается задача построения признакового пространства, необходимого для описания рядов и их классификации. Рассматриваются два основных метода построения признакового пространства. Первый метод заключается в экспертном назначении базовых функций и служит для получения базового признакового пространства и классификации. Второй метод заключается в назначении параметрической гипотезы порождения объекта более сложной структуры. Для каждого временного ряда вычисляются оптимальные параметры порождения, то есть в данном случае коэффициенты авторегрессии. Эти вычисленные параметры и составляют новое признаковое пространство.

В нашей работе на основе методов классификации временных рядов, описанных в [1] и [2], строится новый метод классификации. Как и в [1], целью является найти оптимальный способ сегментации ряда. Предполагается, что временные ряды описывают суперпозицию физической активности, а не отдельное действие. Рассматривается взвешенная сумма различных моделей и инвариантные преобразования рядов: сдвиг и растяжение. В качестве исходных данных используются не только готовые данные WISDM, но и собранные самостоятельно. В качестве базовых алгоритмов рассматриваются методы классификации временных рядов, описанные в более ранних работах. Так, в работе [1] был рассмотрен метод классификации, основанный на признаковом описании ряда. Возникает задача выбора конкретных используемых признаков и выбора аппроксимирующей модели для построения признакового пространства. В работе были исследованы методы, использующие в качестве признаков описаний параметры рядов аппроксимирующей модели, было проведено сравнение моделей аппроксимации, а также предложен алгоритм классификации временных рядов в пространстве параметров распределений признаков их сегментов.

<Тут нужно более подробное описание>

Работа построена следующим образом. *<Описание структуры>*

Постановка задачи классификации временных рядов

Пусть $D(\mathbf{X}, \mathbf{Y})$ — это обучающая выборка, где (\mathbf{X}, ρ) образует метрическое пространство временных рядов, \mathbf{Y} — это метки временных рядов.

Функция F построения множества признаков временного ряда:

$$F : \mathbf{X} \rightarrow \mathbb{R}^n$$

Многоклассовый классификатор G , который переводит признаки в метки:

$$G : \mathbb{R}^n \rightarrow \mathbf{Y}$$

Итоговый алгоритм — это композиция некоторого G и F :

$$a = G \circ F$$

Предлагается в качестве функции потерь использовать индикатор

$$Q(a, D) = \frac{1}{|D|} \sum_{(x,y) \in D} I(a(x) \neq y)$$

В методе обучения будем фиксировать F и оптимизировать функцию G , тогда оптимальный алгоритм принимает следующий вид:

$$a_F = \hat{G} \circ F, \text{ где}$$

$$\hat{G} = \operatorname{argmin}_G (Q(G \circ F, D))$$

Чтобы оценить эффективность метода обучения, мы будем разбивать нашу выборку r раз на тестовую и тренировочную ($D = A_1 \sqcup B_1 = A_2 \sqcup B_2 = \dots = A_r \sqcup B_r$), в таком случае наш критерий качества a_F будет:

$$QV(a_F, D) = \frac{1}{r} \sum_{i=1}^r Q(a_F(A_i), B_i)$$

Итоговая цель — найти:

$$\hat{a} = \operatorname{argmin}_F (QV(a_F, D))$$

Построение признаков

Рассмотрим параметрическую модель, которая будет приближать реальные значения нашего временного ряда:

$$g(w, \mathbf{X}) \rightarrow \mathbf{X}, \text{ где } w \in \mathbb{R}^n.$$

В качестве параметрической модели рассмотрим авторегрессионную модель $AR(p)$:

Пусть $x = [x_1, x_2, \dots, x_t]$ — временной ряд, где $x_i \in \mathbb{R}$

Тогда $g(w, x) = [\hat{x}_1, \hat{x}_2, \dots, \hat{x}_t]$,

$$\text{где } \hat{x}_k = \begin{cases} x_k, & k = 1, \dots, p, \\ w_0 + \sum_{i=1}^p w_i \cdot x_{k-i}, & k = p+1, \dots, t. \end{cases}$$

Если в качестве ρ взять евклидово расстояние, то оптимальное w определяется следующей формулой:

$$w_g(x) = \arg \min_{w \in \mathbb{R}^n} \sum_{i=1}^t \|x_i - \hat{x}_i\|_2^2$$

Алгоритм классификации

Для завершения построения классификатора временных рядов, необходимо построить классификатор G по обучающей выборке $\{(F(x), y) \mid (x, y) \in D\}$.

Будем для этого использовать модель логистической регрессии:

$$f(x, A, b) = A \cdot F(x) + b, \text{ где } A \in M_{m \times n}, b \in M_{m \times 1} \text{ подбираемые параметры.}$$

Далее из вектора $f(x, A, b)$ получаем вектор вероятностей:

$$pr(x, A, b)_k = \frac{e^{f(x, A, b)_k}}{\sum_{i=1}^n e^{f(x, A, b)_i}}$$

Тогда классификатор примет вид:

$$G(x, y) = \operatorname{argmax}_{k=1}^m pr_k(x, A, b)$$

В качестве функции оценки качества параметров тогда будет функция:

$$Loss(x, w, A, b) = \sum_{i=1}^m y_i \cdot \log(pr_i(x, A, b))$$

Оптимальные параметры модели определяются следующим образом:

$$\hat{A}, \hat{b} = \operatorname{argmin}_{A, b} loss(x, w, A, b)$$

Вычислительный эксперимент

Вычислительный эксперимент проводился на данных для задачи классификации типов физической активности человека.

Датасет WISDM

Датасет WISDM [11] содержит показания акселерометра для шести видов человеческой активности:

1. Jogging
2. Walking
3. Upstairs
4. Downstairs
5. Sitting
6. Standing

Необработанные данные, представляющие из себя последовательность размеченных показаний акселерометра (по тройке чисел на каждый отсчет времени с интервалом в 50 миллисекунд), были разбиты на временные ряды длиной по 200 отсчетов (10 секунд).

Модель авторегрессии

Признаковое описание. Каждый временной ряд описывается следующими признаками: среднее значение по каждой из координат, среднее квадратичное отклонение по каждой из координат, средний квадрат ускорения, 10 коэффициентов модели авторегрессии $AR(9)$.

Результаты.

	Jogging	Walking	Upstairs	Downstairs	Sitting	Standing	Total quality
KNN ($k = 1$)	99.40%	98.82%	93.81%	87.34%	98.04%	100.00%	97.61%
Random forest (100 trees)	99.70%	99.29%	88.50%	81.01%	96.08%	100.00%	96.75%
Log regression	99.40%	96.00%	78.76%	43.04%	92.16%	97.67%	91.10%

Таблица 1. Качество модели авторегрессии на датасете WISDM




Рис. 1. Точность классификации при использовании модели авторегрессии и классификатора KNN.




Рис. 2. Точность классификации при использовании модели авторегрессии и Random forest.




Рис. 3. Точность классификации при использовании модели авторегрессии и логистической регрессии.

Как видно, все три классификатора показывают хорошие результаты и классифицируют данные с точностью более 91%. В то же время, наилучшие результаты показывает KNN, при этом все классификаторы показывают наихудшие результаты для классов «Upstairs» и «Downstairs». При этом, все алгоритмы можно улучшать с помощью, например, добавления дополнительных признаков или перебора параметров классификаторов.

Коэффициенты Фурье

Признаковое описание. ...

Результаты.

	Jogging	Walking	Upstairs	Downstairs	Sitting	Standing	Total quality
KNN (k = 1)	98.80%	97.78%	39.00%	26.92%	100.00%	100.00%	82.20%
Random forest (100 trees)	98.80%	99.01%	63.00%	54.80%	100.00%	100.00%	91.20%
Log regression	93.69%	97.04%	22.00%	16.35%	94.00%	100.00%	80.77%

Таблица 2. Качество коэффициентов Фурье на датасете WISDM

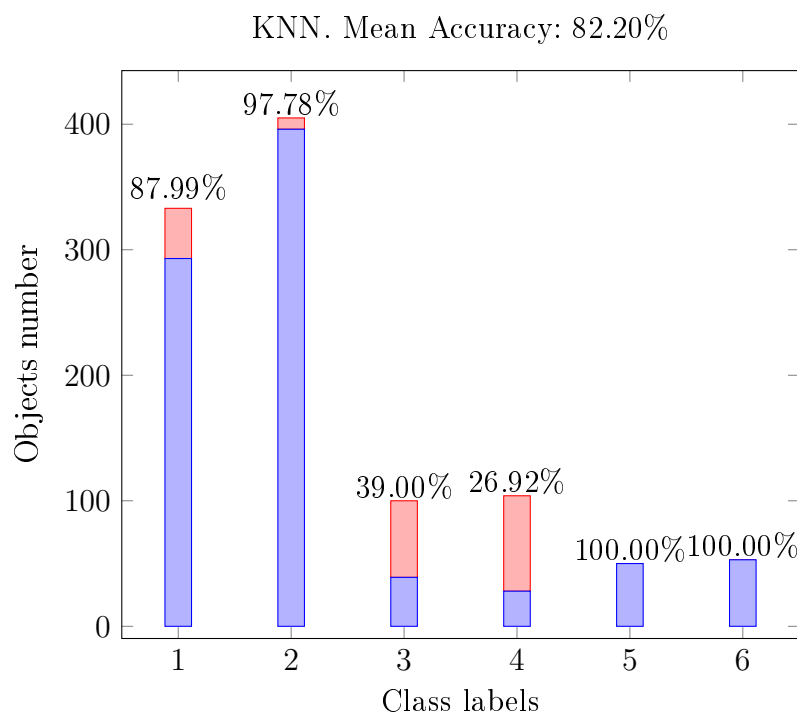


Рис. 4. Точность классификации при использовании коэффициентов Фурье и классификатора KNN.




Рис. 5. Точность классификации при использовании коэффициентов Фурье и Random forest.




Рис. 6. Точность классификации при использовании коэффициентов Фурье и логистической регрессии.



Линейное преобразование ряда и модель авторегрессии

Признаковое описание. ...

Результаты.

	Jogging	Walking	Upstairs	Downstairs	Sitting	Standing	Total quality
KNN (k = 1)	99.70%	99.53%	95.83%	83.13%	96.15%	100.00%	97.80%
Random forest (100 trees)	99.44%	99.24%	89.62%	71.60%	98.46%	100.00%	96.17%
Log regression	93.69%	97.04%	22.00%	16.35%	94.00%	100.00%	80.77%

Таблица 3. Качество комбинирования линейного преобразования рядов и модели авторегрессии на датасете WISDM



Литература

- [1] Карасиков М.Е., Стрижов В.В. Классификация временных рядов в пространстве параметров порождающих моделей // Информатика и ее применения, 2016.

- [2] Кузнецов М.П., Ивкин Н.П. Алгоритм классификации временных рядов акселерометра по комбинированному признаковому описанию // *Машинное обучение и анализ данных*, 2015. Т. 1, № 11. С. 1471 - 1483.
- [3] Исаченко Р.В., Стрижов В.В. Метрическое обучение в задачах многоклассовой классификации временных рядов // *Информатика и ее применения*, 2016, 10(2) : 48-57.
- [4] Задаянчук А.И., Попова М.С., Стрижов В.В. Выбор оптимальной модели классификации физической активности по измерениям акселерометра // *Информационные технологии*. 2016.
- [5] Motrenko A.P., Strijov V.V. Extracting fundamental periods to segment human motion time series // *Journal of Biomedical and Health Informatics*, 2016, Vol. 20, No. 6, 1466 - 1476.
- [6] Ignatov A., Strijov V. Human activity recognition using quasiperiodic time series collected from a single triaxial accelerometer // *Multimedia Tools and Applications*, 2015, 17.05.2015 : 1-14.
- [7] Кузнецова М.В. Классификация временных рядов с использованием инвариантных преобразований // *Выпускная квалификационная работа магистра*, 2015, Московский физико-технический институт.
- [8] Фадеев И.В. Выбор иерархических моделей в авторегрессионном прогнозировании // *Магистерская диссертация*, 2013, Московский физико-технический институт.
- [9] Исаченко Р.В. Реализация алгоритма классификации временных рядов // *sourceforge.net*, <http://sourceforge.net/p/mlalgorithms/code/HEAD/tree/Group274/Isachenko2015TimeSeries/code/>.
- [10] Кононенко Д.С. Оценка параметров инвариантных преобразований в задачах прогнозирования временных рядов // *Магистерская диссертация*, 2013, Московский физико-технический институт.
- [11] *Wisdms activity prediction dataset* // , 2012, <http://www.cis.fordham.edu/wisdms/dataset.php>.
- [12] Oliver Amft Analysis of Movement, Orientation and Rotation-Based Sensing for Phone Placement Recognition // *Sensors*, 2015.
- [13] Akram Bayat, Marc Pomplun, Duc A. Tran A Study on Human Activity Recognition Using Accelerometer Data from Smartphones // *The 11th International Conference on Mobile Systems and Pervasive Computing*, 2014.
- [14] Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, and Jorge L. Reyes-Ortiz Human Activity Recognition on Smartphones using a Multiclass Hardware-Friendly Support Vector Machine // *Proceedings of the 4th international conference on Ambient Assisted Living and Home Care*, 2012.
- [15] Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, and Jorge L. Reyes-Ortiz A Public Domain Dataset for Human Activity Recognition Using Smartphones // *21th European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning*, 2013.
- [16] Xiangbin Zhu, Huiling Qiu High Accuracy Human Activity Recognition Based on Sparse Locality Preserving Projections // *PLoS ONE*, 2016.
- [17] Haritha Vellampalli Physical Human Activity Recognition Using Machine Learning Algorithms // *Dissertation*, Dublin Institute of Technology, 2017.
- [18] Muhammad Shoaib, Stephan Bosch, Ozlem Durmaz Incel, Hans Scholten, and Paul J. M. Havinga Complex Human Activity Recognition Using Smartphone and Wrist-Worn Motion Sensors // *Sensors*, 2016.
- [19] Shinki Miyamoto, Hitoshi Ogawa Human Activity Recognition System Including Smartphone Position // *International workshop on Innovations in Information and Communication Science and Technology*, 2014.

- [20] *Charissa Ann Ronao, Sung-Bae Cho* Recognizing human activities from smartphone sensors using hierarchical continuous hidden Markov models // *International Journal of Distributed Sensor Networks*, 2017, Vol. 13(1).
- [21] *Dina Bousdar Ahmed, Korbinian Frank, Oliver Heirich* Recognition of Professional Activities With Displaceable Sensors // *Vehicular Technology Conference*, 2015.
- [22] *Shah Md. Shihab Hasan, Mohshi Masnad, Md. Mohiuddin Khan, Hasan Mahmud, Md. Kamrul Hasan* Human Activity Recognition using Smartphone Sensors with Context Filtering // *The Ninth International Conference on Advances in Computer-Human Interactions*, 2016.