

Классификация суперпозиций движений физической активности*

Проскурин А. Д., Бельх Е. А.

proskurin.ad@phystech.edu, belyh.ea@phystech.edu

Московский физико-технический институт (государственный университет), Москва

В работе рассматривается задача анализа поведения человека по измерениям датчиков мобильного телефона. Исследуются временные ряды, построенные по показаниям акселерометра телефона. Данные представляют собой временные ряды сигнала, не имеющего точной периодики, а также содержащие неизвестную суперпозицию физической активности. В работе ищется оптимальный способ сегментации и оптимальное описание временного ряда. Строится метрическое пространство описаний элементарных действий. Предложен новый способ классификации и анализа сложных движений.

Ключевые слова: *временные ряды, классификация, распознавание физической деятельности, суперпозиция движений.*

Classification of superposition of physical activity*

Proskurin A. D., Belykh E. A

Moscow Institute of Physics and Technology (state university), Moscow

Here should be abstract in English.

Keywords: *machine learning, time series, classification, physical activity recognition, action superposition.*

Введение

Решается задача классификации активности человека, что в перспективе поможет следить за его физическим и душевным состоянием. Целью данной работы является распознать сложные движения человека, являющиеся суперпозицией простых движений, используя данные акселерометра телефона. Задача анализа физической активности человека по временным рядам, полученным с помощью акселерометра, рассматривалась в [1, 2, 6, 4]. При этом, в [1, 2] движение рассматривается как простой процесс, а не суперпозиция нескольких действий.

Для классификации временных рядов акселерометра в [4] используется нейронная сеть оптимальной структуры. Найденная устойчивая модель описывается с помощью генетического алгоритма на уровне нейронов путем оптимизации структурных параметров. В [6] используется алгоритм k ближайших соседей. Результаты показывают, что оптимальным оказывается комбинирование продвинутых алгоритмов сегментации и алгоритма k ближайших соседей. В некоторых работах рассматривается композиция движений, либо зависимость движения от местоположения акселерометра. Так, в [18] используются три классификатора: наивный байесовский, метод k ближайших соседей, решающее дерево. С их помощью производится анализ тринадцати типов движений, некоторые из которых являются простыми, а некоторые композицией простых. Особый интерес представляют

Научный руководитель: Стрижов В. В. Задачу поставил: Стрижов В. В. Консультанты: Владимирова М. Р., Малькова А. С.

работы [22, 19, 21], в которых описываются алгоритмы анализа не только типа физической активности человека, но и анализа местоположения акселерометра во время физической активности. В [19] применяется гистограмма направленных градиентов для преобразования временных рядов и приведения их к более простому виду. Классификация рядов по типам физической активности и местоположению акселерометра делается с помощью алгоритма AdaBoost.

Одной из задач является поиск оптимального способа сегментации и описания временного ряда, а также построение метрического пространства описаний физической активности. В [1, 2] исследуются различные методы признакового описания временных рядов, на основе которых проводится классификация. При этом, в [1] в качестве признаков описаний используются параметры аппроксимирующих моделей, а в [2] используется модель авторегрессии и модель сингулярного спектра временного ряда. В нашей работе предлагается рассмотреть инвариантные преобразования временных рядов, как это было сделано в [7]. В [22, 19, 21] используются разные способы описания временных рядов и их классификации. Так, в [21] используется динамическая байесовская сеть. В [22] используется алгоритм динамической трансформации временной шкалы для нахождения оптимального соответствия между временными рядами, а затем преобразованные ряды классифицируются с помощью алгоритма k ближайших соседей.

В [2] рассматривается задача построения признакового пространства, необходимого для описания рядов и их классификации. Рассматриваются два основных метода построения признакового пространства. Первый метод заключается в экспертном назначении базовых функций и служит для получения базового признакового пространства и классификации. Второй метод заключается в назначении параметрической гипотезы порождения объекта более сложной структуры. Для каждого временного ряда вычисляются оптимальные параметры порождения, то есть в данном случае коэффициенты авторегрессии. Эти вычисленные параметры и составляют новое признаковое пространство.

В нашей работе на основе методов классификации временных рядов, описанных в [1, 2], строится новый метод классификации. Рассматривается взвешенная сумма различных моделей и инвариантные преобразования рядов: сдвиг и растяжение. В качестве исходных данных используются не только данные WISDM [11], но и собранные самостоятельно. В качестве базовых алгоритмов рассматриваются методы классификации временных рядов, описанные в более ранних работах. Так, в работе [1] был рассмотрен метод классификации, основанный на признаковом описании ряда. Решается задача выбора конкретных используемых признаков и выбора аппроксимирующей модели для построения признакового пространства. В работе были исследованы методы, использующие в качестве признаков описаний параметры рядов аппроксимирующей модели, было проведено сравнение моделей аппроксимации, а также предложен алгоритм классификации временных рядов в пространстве параметров распределений признаков их сегментов. *<Тут нужно более подробное описание>*

Постановка задачи классификации временных рядов

Пусть $\{(\mathbf{x}_i, \mathbf{y}_i)\}$ — это обучающая выборка, где \mathbf{x} — временной ряд, имеющий большую длину, чем наиболее продолжительная рассматриваемая суперпозиция, \mathbf{y} — это рассматриваемые типы суперпозиций физической активности.

Рассматриваются следующие виды суперпозиций физической активности:

h \ g	No nand motion	Look at watch	Take a sip, 33cl	Carry sack (right hand), 2kg
Stand	id+id	id+g2	id+g3	id+id
Walk normal	h2+id	h2+g2	h2+g3	h2+g4
Downstairs	h3+id	h3+g2	h3+g3	h3+g4
Jog	h4+id	h4+g2	h4+g3	h4+g4

Таблица 1. Типы рассматриваемых суперпозиций физической активности

Данные для работы собираются по следующему квесту:

- Поставить воду 300cl, пакет с бутылкой 2l на стол.
- Запустить приложение [название].
- Проверить частоту семплирования, [100Hz].
- Нажать на кнопку Старт
- Повторять: Топнуть, Действие из списка, считать про себя до пяти. Действие рук повторять не спеша.
- Нажать кнопку Стоп.
- Сохранить файл.
- Послать по специальному адресу файл и анкету со следующим данными:
 1. sex, age, weight, height,
 2. morning, evening, exited, calm,
 3. left back pocket, left hand, left hand bag (for phone).

Список действий:

- Надеть рюкзак (на оба плеча). Снять рюкзак. 10 раз, перерыв между действиями по 2 секунды.
- Снять очки. Надеть очки. 10 раз, перерыв между действиями по 2 секунды.
- Шагать — 3 минуты.
- Шагать на месте — 3 минуты.
- 25 приседаний.
- Поднести чашку со стола ко рту, поставить чашку. 20 раз, перерыв между действиями по 2 секунды.

Функция F построения множества признаков временного ряда:

$$F : \mathbf{X} \rightarrow \mathbb{R}^n$$

Многоклассовый классификатор G , который переводит признаки в метки:

$$G : \mathbb{R}^n \rightarrow \mathbf{Y}$$

Итоговый алгоритм — это композиция некоторого G и F :

$$a = G \circ F$$

Предлагается в качестве функции потерь использовать индикатор

$$Q(a, D) = \frac{1}{|D|} \sum_{(x,y) \in D} I(a(x) \neq y)$$

В методе обучения будем фиксировать F и оптимизировать функцию G , тогда оптимальный алгоритм принимает следующий вид:

$$a_F = \hat{G} \circ F, \text{ где}$$

$$\hat{G} = \operatorname{argmin}_G(Q(G \circ F, D))$$

Чтобы оценить эффективность метода обучения, мы будем разбивать нашу выборку r раз на тестовую и тренировочную ($D = A_1 \sqcup B_1 = A_2 \sqcup B_2 = \dots = A_r \sqcup B_r$), в таком случае наш критерий качества a_F будет:

$$QV(a_F, D) = \frac{1}{r} \sum_{i=1}^r Q(a_F(A_i), B_i)$$

Итоговая цель — найти:

$$\hat{a} = \operatorname{argmin}_F(QV(a_F, D))$$

Модель локальной аппроксимации SEMOR

Модель **SEMOR** решает задачу аппроксимации отнормированного временного ряда Z временным рядом \mathbf{x} .

Для этого производится преобразование ряда \mathbf{x} .

Преобразованием ряда является его сдвиг и растяжение, то есть выбор коэффициентов ω_1 и ω_2 и переход от ряда $\mathbf{x}(t)$ к ряду $\mathbf{x}(\omega_1 * t + \omega_2)$.

Таким образом, задача заключается в поиске таких коэффициентов ω_1 и ω_2 , что величина $\|Z - \mathbf{x}(\omega_1 * t + \omega_2)\|$ минимизируется.

Для решения задачи классификации суперпозиции физической активности используется модель **SEMOR** для двух рядов.

Пусть есть отнормированный ряд Z , который необходимо классифицировать. Также есть два множества отнормированных рядов $\{G_1, G_2, \dots, G_n\}$ и $\{H_1, H_2, \dots, H_m\}$.

Необходимо найти такую пару рядов G_i и H_j , что Z является их суперпозицией. Для этого нужно преобразовать ряды и построить их суперпозицию Q .

Суперпозицией преобразованных рядов является их сумма, которая также преобразована с помощью сдвига и растяжения:

$$Q = \omega_5 * (G_i(\omega_1 * t + \omega_2) + H_j(\omega_3 * t + \omega_4)) + \omega_6$$

Таким образом, необходимо найти:

$$\operatorname{argmin}_{(i,j)} \|Q - Z\|,$$

где все ω в Q выбраны так, что они минимизируют значение функции.

Модель локальной аппроксимации AR

Рассмотрим параметрическую модель, которая будет приближать реальные значения нашего временного ряда:

$$g(w, \mathbf{X}) \rightarrow \mathbf{X}, \text{ где } w \in \mathbb{R}^n.$$

В качестве параметрической модели рассмотрим авторегрессионную модель $AR(p)$:

Пусть $x = [x_1, x_2, \dots, x_t]$ — временной ряд, где $x_i \in \mathbb{R}$

Тогда $g(w, x) = [\hat{x}_1, \hat{x}_2, \dots, \hat{x}_t]$,

$$\text{где } \hat{x}_k = \begin{cases} x_k, & k = 1, \dots, p, \\ w_0 + \sum_{i=1}^p w_i \cdot x_{k-i}, & k = p+1, \dots, t. \end{cases}$$

Если в качестве ρ взять евклидово расстояние, то оптимальное w определяется следующей формулой:

$$w_g(x) = \arg \min_{w \in \mathbb{R}^n} \sum_{i=1}^t \|x_i - \hat{x}_i\|_2^2$$

Алгоритм классификации

Для завершения построения классификатора временных рядов, необходимо построить классификатор G по обучающей выборке $\{(F(x), y) \mid (x, y) \in D\}$.

Будем для этого использовать модель логистической регрессии:

$$f(x, A, b) = A \cdot F(x) + b, \text{ где } A \in M_{m \times n}, b \in M_{m \times 1} \text{ подбираемые параметры.}$$

Далее из вектора $f(x, A, b)$ получаем вектор вероятностей:

$$pr(x, A, b)_k = \frac{e^{f(x, A, b)_k}}{\sum_{i=1}^n e^{f(x, A, b)_i}}$$

Тогда классификатор примет вид:

$$G(x, y) = \arg \max_{k=1}^m pr_k(x, A, b)$$

В качестве функции оценки качества параметров тогда будет функция:

$$Loss(x, w, A, b) = \sum_{i=1}^m y_i \cdot \log(pr_i(x, A, b))$$

Оптимальные параметры модели определяются следующим образом:

$$\hat{A}, \hat{b} = \arg \min_{A, b} loss(x, w, A, b)$$

Базовый вычислительный эксперимент

Датасет WISDM

Датасет WISDM [11] содержит показания акселерометра для шести видов человеческой активности:

1. Jogging
2. Walking
3. Upstairs
4. Downstairs

5. Sitting
6. Standing

Необработанные данные, представляющие из себя последовательность размеченных показаний акселерометра (по тройке чисел на каждый отсчет времени с интервалом в 50 миллисекунд), были разбиты на временные ряды длиной по 200 отсчетов (10 секунд).

Модель авторегрессии

Признаковое описание. Каждый временной ряд описывается следующими признаками: среднее значение по каждой из координат, среднее квадратичное отклонение по каждой из координат, средний квадрат ускорения, 10 коэффициентов модели авторегрессии $AR(9)$.

Результаты.

	Jogging	Walking	Upstairs	Downstairs	Sitting	Standing	Total quality
KNN (k = 1)	99.40%	98.82%	93.81%	87.34%	98.04%	100.00%	97.61%
Random forest (100 trees)	99.70%	99.29%	88.50%	81.01%	96.08%	100.00%	96.75%
Log regression	99.40%	96.00%	78.76%	43.04%	92.16%	97.67%	91.10%

Таблица 2. Качество модели авторегрессии на датасете WISDM




Рис. 1. Точность классификации при использовании модели авторегрессии и классификатора KNN.

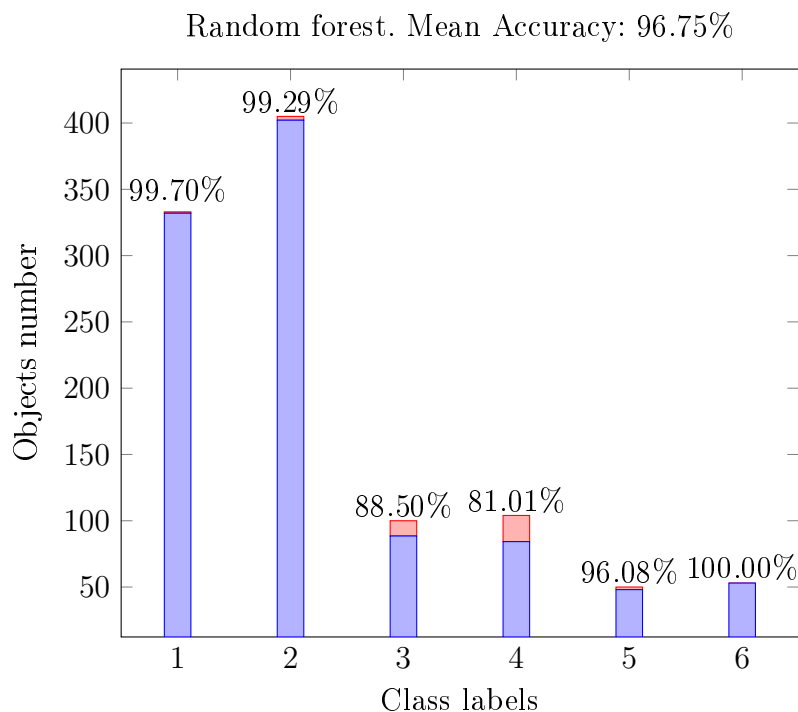


Рис. 2. Точность классификации при использовании модели авторегрессии и Random forest.

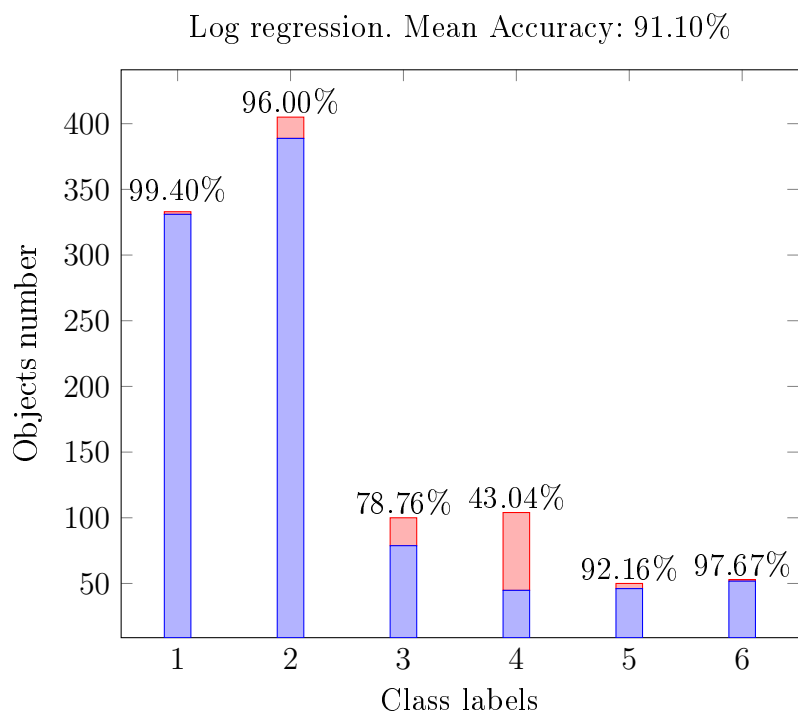


Рис. 3. Точность классификации при использовании модели авторегрессии и логистической регрессии.

Как видно, все три классификатора показывают хорошие результаты и классифицируют данные с точностью более 91%. В то же время, наилучшие результаты показывает KNN, при этом все классификаторы показывают наихудшие результаты для классов «Upstairs» и «Downstairs». При этом, все алгоритмы можно улучшать с помощью, например, добавления дополнительных признаков или перебора параметров классификаторов.

Коэффициенты Фурье

Признаковое описание. ...

Результаты.

	Jogging	Walking	Upstairs	Downstairs	Sitting	Standing	Total quality
KNN (k = 1)	98.80%	97.78%	39.00%	26.92%	100.00%	100.00%	82.20%
Random forest (100 trees)	98.80%	99.01%	63.00%	54.80%	100.00%	100.00%	91.20%
Log regression	93.69%	97.04%	22.00%	16.35%	94.00%	100.00%	80.77%

Таблица 3. Качество коэффициентов Фурье на датасете WISDM




Рис. 4. Точность классификации при использовании коэффициентов Фурье и классификатора KNN.




Рис. 5. Точность классификации при использовании коэффициентов Фурье и Random forest.




Рис. 6. Точность классификации при использовании коэффициентов Фурье и логистической регрессии.



Линейное преобразование ряда и модель авторегрессии

Признаковое описание. ...

Результаты.

	Jogging	Walking	Upstairs	Downstairs	Sitting	Standing	Total quality
KNN (k = 1)	99.70%	99.53%	95.83%	83.13%	96.15%	100.00%	97.80%
Random forest (100 trees)	99.44%	99.24%	89.62%	71.60%	98.46%	100.00%	96.17%
Log regression	93.69%	97.04%	22.00%	16.35%	94.00%	100.00%	80.77%

Таблица 4. Качество комбинирования линейного преобразования рядов и модели авторегрессии на датасете WISDM



Литература

- [1] Карасиков М.Е., Стрижов В.В. Классификация временных рядов в пространстве параметров порождающих моделей // *Информатика и ее применения*, 2016.

- [2] Кузнецов М.П., Ивкин Н.П. Алгоритм классификации временных рядов акселерометра по комбинированному признаковому описанию // *Машинное обучение и анализ данных*, 2015. Т. 1, № 11. С. 1471 - 1483.
- [3] Исаченко Р.В., Стрижов В.В. Метрическое обучение в задачах многоклассовой классификации временных рядов // *Информатика и ее применения*, 2016, 10(2) : 48-57.
- [4] Задаянчук А.И., Попова М.С., Стрижов В.В. Выбор оптимальной модели классификации физической активности по измерениям акселерометра // *Информационные технологии*. 2016.
- [5] Motrenko A.P., Strijov V.V. Extracting fundamental periods to segment human motion time series // *Journal of Biomedical and Health Informatics*, 2016, Vol. 20, No. 6, 1466 - 1476.
- [6] Ignatov A., Strijov V. Human activity recognition using quasiperiodic time series collected from a single triaxial accelerometer // *Multimedia Tools and Applications*, 2015, 17.05.2015 : 1-14.
- [7] Кузнецова М.В. Классификация временных рядов с использованием инвариантных преобразований // *Выпускная квалификационная работа магистра*, 2015, Московский физико-технический институт.
- [8] Фадеев И.В. Выбор иерархических моделей в авторегрессионном прогнозировании // *Магистерская диссертация*, 2013, Московский физико-технический институт.
- [9] Исаченко Р.В. Реализация алгоритма классификации временных рядов // *sourceforge.net*, <http://sourceforge.net/p/mlalgorithms/code/HEAD/tree/Group274/Isachenko2015TimeSeries/code/>.
- [10] Кононенко Д.С. Оценка параметров инвариантных преобразований в задачах прогнозирования временных рядов // *Магистерская диссертация*, 2013, Московский физико-технический институт.
- [11] *WisdM's activity prediction dataset* // , 2012, <http://www.cis.fordham.edu/wisdM/dataset.php>.
- [12] *Oliver Amft Analysis of Movement, Orientation and Rotation-Based Sensing for Phone Placement Recognition* // *Sensors*, 2015.
- [13] *Akram Bayat, Marc Pomplun, Duc A. Tran A Study on Human Activity Recognition Using Accelerometer Data from Smartphones* // *The 11th International Conference on Mobile Systems and Pervasive Computing*, 2014.
- [14] *Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, and Jorge L. Reyes-Ortiz Human Activity Recognition on Smartphones using a Multiclass Hardware-Friendly Support Vector Machine* // *Proceedings of the 4th international conference on Ambient Assisted Living and Home Care*, 2012.
- [15] *Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, and Jorge L. Reyes-Ortiz A Public Domain Dataset for Human Activity Recognition Using Smartphones* // *21th European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning*, 2013.
- [16] *Xiangbin Zhu, Huiling Qiu High Accuracy Human Activity Recognition Based on Sparse Locality Preserving Projections* // *PLoS ONE*, 2016.
- [17] *Haritha Vellampalli Physical Human Activity Recognition Using Machine Learning Algorithms* // *Dissertation*, Dublin Institute of Technology, 2017.
- [18] *Muhammad Shoaib, Stephan Bosch, Ozlem Durmaz Incel, Hans Scholten, and Paul J. M. Havinga Complex Human Activity Recognition Using Smartphone and Wrist-Worn Motion Sensors* // *Sensors*, 2016.
- [19] *Shinki Miyamoto, Hitoshi Ogawa Human Activity Recognition System Including Smartphone Position* // *International workshop on Innovations in Information and Communication Science and Technology*, 2014.

- [20] *Charissa Ann Ronao, Sung-Bae Cho* Recognizing human activities from smartphone sensors using hierarchical continuous hidden Markov models // *International Journal of Distributed Sensor Networks*, 2017, Vol. 13(1).
- [21] *Dina Bousdar Ahmed, Korbinian Frank, Oliver Heirich* Recognition of Professional Activities With Displaceable Sensors // *Vehicular Technology Conference*, 2015.
- [22] *Shah Md. Shihab Hasan, Mohshi Masnad, Md. Mohiuddin Khan, Hasan Mahmud, Md. Kamrul Hasan* Human Activity Recognition using Smartphone Sensors with Context Filtering // *The Ninth International Conference on Advances in Computer-Human Interactions*, 2016.